

Thrift

זיכרון ממוקד-עלות לציי סוכני AI

מדריך למשתמש · רישיון Apache-2.0 · בשימוש פנימי · גרסת x.0.0 מוקדמת

איך זה עובד — בקצרה

הבעיה: לכל סוכן AI יש "זיכרון" — קובץ עם כל מה שהוא צריך לדעת. הבעיה שבכל פעם שהסוכן רץ, הוא טוען את כל הקובץ מחדש, גם את ה-99% שלא רלוונטיים למשימה הנוכחית. כשיש לך 20 סוכנים שרצים כל היום, אתה משלם שוב ושוב על אותו מידע מיותר. זה הבזבז הכי גדול בחשבון.

מה Thrift עושה: במקום "תטען הכל", Thrift טוען רק את הזיכרון הרלוונטי למשימה הספציפית. הסוכן שואל "אני עכשיו מתקן באג ב-proxy" — ו-Thrift מחזיר לו רק את הזיכרונות שקשורים לזה, תחת תקציב טוקנים קבוע. Thrift מסנן זיכרונות לא רלוונטיים במקום להכניס כל דבר שנכנס בתקציב.

הקסם השני — הוכחה: בכל פעם ש-Thrift טוען זיכרון, הוא רושם קבלה: כמה היית משלם אם היית טוען הכל מול כמה שילמת בפועל. הלוח שלך מציג את ההפרש בזמן אמת. זה לא "תאמין לי שחסכת" — זה מספר מדוד.

שתי דרכים להתחבר: או שהסוכן קורא ישירות לכלי הזיכרון של Thrift (MCP), או שמציבים את Thrift כ-proxy באמצע ומשנים שורה אחת בהגדרות — ואז הוא גוזם את הבזבז אוטומטית בלי לגעת בקוד של הסוכן.

התקנה ב-3 צעדים (MCP)

1. הוסיפו קובץ `.mcp.json` בשורש הפרויקט עם הבלוק הבא:

```
{
  "mcpServers": {
    "thrift": { "command": "npx", "args": ["thrift-memory"] }
  }
}
```

2. הפעילו מחדש את הסוכן (Claude Code / Cursor / Windsurf) — הוא יזהה אוטומטית את הכלים, `recall`, `remember`, `search_memory`. אין צורך לכתוב קוד מחדש.

3. זהו. הסוכן עכשיו טוען רק את הזיכרון שצריך. אין צורך בהתקנה ידנית — `npx` מושך את החבילה מ-npm אוטומטית.

אופציה: התקנה דרך npm

אם מעדיפים להתקין את החבילה במקום להריץ דרך `npx`:

```
# global install
npm install -g thrift-memory

# then run directly (or use "command": "thrift-memory" in .mcp.json):
thrift-memory --store-path=~/.thrift/memories.json1 --default-budget=2000
```

כלי	מה הוא עושה
<code>recall(agentId, tokenBudget, task)</code>	טוען רק את הזיכרונות הרלוונטיים למשימה תחת תקציב ה-token, ומחזיר קבלה: { injectedTokens, baselineTokens, savedTokens }. זה הכלי שחוסך את הכסף.
<code>remember(scope, text, agentId?, sessionId?, tags?, pinned?)</code>	נתיב כתיבה זול — שומר זיכרון. חובה: (org / agent / session) scope. נדרש רק ב-scope של agent. מהיר וחינמי, בלי העשרת LLM חובה.
<code>search_memory(agentId, task?, tags?, limit?)</code>	חיפוש בזיכרונות בלי תקציב — לעיון או ללוח הבקרה.

אופציה ב' — Proxy (בלי לגעת בקוד)

לסוכן ששולח מחדש את כל ה-prompt בכל תור, מציבים את Thrift כ-proxy ומשנים רק את ה-base_url. הוא גוזם ומודד כל בקשה, מעביר ל-upstream, וגם מטפל אוטומטית בשגיאות 429 (ניסיון חוזר עם backoff וכיבוד -Retry). (After)

```
npx thrift-proxy \
  --upstream=https://api.anthropic.com \
  --port=8787 \
  --budget=4000 \
  --meter-path=~/.thrift/meter.jsonl
# then point the agent's base_url to http://localhost:8787 (keep your real API key)
```

אבטחה: ברירת המחדל היא הרצה מקומית בלבד על 127.0.0.1, כי ה-proxy מעביר את מפתח ה-API האמיתי שלכם ל-upstream. אל תפתחו אותו ל-0.0.0.0 אלא אם אתם יודעים בדיוק למה (דרך / --host THIRIFT_PROXY_HOST). הקבלה של ה-proxy נמדדת לפי הבקשה שבאמת נשלחה, כדי לא לדווח חיסכון מוגזם.

לראות את החיסכון — לוח הבקרה

ממשק דפדפן מקומי, בלי בסיס נתונים ובלי build. קורא את אותם קבצים שה-MCP וה-proxy כותבים, ומציג סיכום צי, זרימה יומית, חיסכון לפי סוכן וקבלות אחרונות.

```
npx thrift-panel serve
# open http://127.0.0.1:8585
```

במשפט אחד: Thrift = "תטען רק מה שצריך, ותראה במספרים כמה חסכת."

Thrift — זיכרון ממוקד-עלות לציי סוכני AI · רישיון Apache-2.0 · הגדרות נוספות (, THIRIFT_DEFAULT_BUDGET, THIRIFT_STORE_PATH, THIRIFT_MAX_RETRIES (ועוד) — ב-README.